




## História da Teoria da Evolução

- **1859: Charles Darwin**
  - **Existe uma diversidade de seres devido aos contingentes da natureza (comida, clima, ...) e é pela lei da Seleção Natural que os seres mais adaptados ao seus ambientes sobrevivem**
    - contra lei do uso e desuso
  - **Os caracteres adquiridos são herdados pelas gerações seguintes**



**“Quanto melhor um indivíduo se adaptar ao seu meio ambiente, maior será sua chance de sobreviver e gerar descendentes.”**

**(DARWIN, 1859)**



## História da Teoria da Evolução

### □ 1865: Gregor Mendel

- **Formalizou a “herança de características”, com a teoria do DNA (ervilhas)**

### □ 1901: Hugo De Vries

- **Só a seleção natural não é responsável pela produção de novas (mais adaptadas) espécies. Tem de haver uma mudança genética!**
- **Formalizou o processo de geração de diversidade: Teoria da Mutação**



## Surgimento dos Algoritmos Genéticos

### □ 1975: Jonh Holland: Idealizou os algoritmos genéticos

### □ Por que a evolução ?

- **Muitos problemas computacionais**
  - envolvem busca através de um grande número de possíveis soluções
  - requerem que o programa seja adaptativo, apto a agir em um ambiente dinâmico
- **A evolução biológica**
  - uma busca paralela em um enorme espaço de problema
  - soluções desejadas = organismos mais adaptados



## Algoritmos Genéticos: introdução

### □ Algoritmos Evolutivos

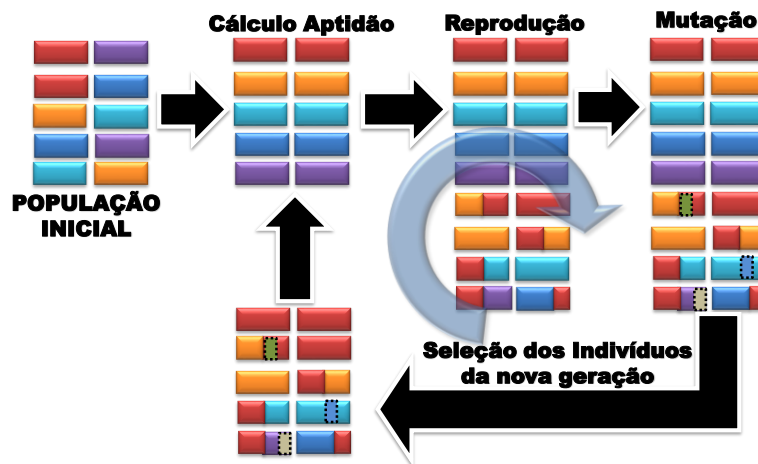
- Método para resolução de problemas (otimização) “inspirado” na teoria da evolução
- Algoritmos Genéticos são Algoritmos Evolutivos

### □ Algoritmo Genético

- indivíduo = solução
- provoca mudança nos indivíduos por intermédio de *mutação e reprodução*
- *seleciona* indivíduos mais adaptados através de sucessivas gerações
- A aptidão de cada indivíduo é medida pela “função de aptidão” (*fitness function*)

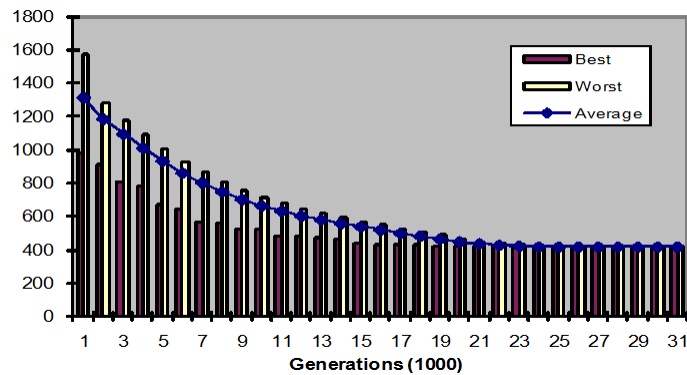


## Ciclo do Algoritmo Genético





## Convergência das gerações



## Gerando População Inicial

- Dado um problema, precisamos definir como será a representação dos indivíduos (soluções)
- Um indivíduo é um Cromossomo
  - Os parâmetros do problema de otimização são representados por cadeias de valores.
  - Exemplos:
    - Vetores de reais, (2.345, 4.3454, 5.1, 3.4)
    - Cadeias de bits, (111011011)
    - Vetores de inteiros, (1,4,2,5,2,8)
    - ou outra estrutura de dados (árvores, heaps, etc)



## Gerando População Inicial

- Qual deve ser a população Inicial ?
  - Deve ser aleatoriamente escolhida
  - *Precisamos garantir a variedade da população inicial:*
    - velocidade de convergência x variedade
    - Variedade x solução ótima
    - Quanto maior a variedade, menor a velocidade de convergência e vice-versa
    - Quanto maior a variedade, maior a chance de encontrar a solução ótima, porém, menor a velocidade de convergência




## Função de Aptidão- Fitness

- **Função de aptidão (avaliação / fitness):**
  - É feita através de uma função que melhor representa o problema e tem por objetivo fornecer uma medida de aptidão de cada indivíduo na população corrente que irá dirigir o processo de busca.
  - Aptidão é uma nota associada ao indivíduo que avalia quão boa é a solução por ele representada

- **Funções de avaliação são específicas de cada problema.**

- | ▫ Cromossomo | Significado        | valor    |
|--------------|--------------------|----------|
| ▫ 0011011    | Binário p/ Inteiro | $x = 27$ |

- ADBCE



$$\sum_{\text{dist}} A \rightarrow D \rightarrow B \rightarrow C \rightarrow E = 13$$




## Criando e Evoluindo Gerações

- Quais são os métodos para criar novos indivíduos ?
  - Reprodução sexuada (crossover)
  - Reprodução assexuada
  - Mutação
- Como garantir encontrar a solução ?
  - Os indivíduos devem ser selecionados (os mais aptos sobrevivem) para garantir a convergência
  - Deve-se evitar a convergência prematura
  - Deve-se estabelecer um critério de parada
- Convergência
  - nas últimas  $k$  gerações não houve melhora da aptidão



## Reprodução/recombinação


- Função: combinar e/ou perpetuar material genético dos indivíduos mais adaptados
- Tipos:
  - assexuada (=duplicação) ou sexuada (crossover)
  - Observação: Existe uma “taxa de crossover” que controla a quantidade de reprodução que será feita






## Reprodução

- Quanto mais “estruturada” a representação mais difícil de definir o cruzamento



## Mutação


- **Objetivo:** gerar diversidade (p/ escapar de ótimos locais)
- **Tipos:**
  - generativa
  - destrutiva
  - swap
  - swap de sequência
- **Observação:** Existe uma “taxa de mutação” que diminui com o tempo (ex. % da população selecionada) para garantir convergência







## Reprodução e Mutação



### □ Composições possíveis para a População 2:

- **Troca de toda população**
  - Isso significa que a população 2 substitui a população 1
  - A cada ciclo,  $N/2$  pares são escolhidos gerando  $M=N$  descendentes
- **Elitismo**
  - A população 2 substitui a população 1 ( $M= N-1$ )
  - Acrescenta-se o mais apto da população 1 na população 2
- **Steady State**
  - Gera-se  $M<N$  indivíduos e esses  $M$  substituem os  $M$  piores do conjunto da população 1 – Existe também o Steady state sem duplicados




## Seleção de indivíduos para Reprodução

### □ Como selecionar indivíduos para Reprodução ?

#### □ Método da Roleta

- Selecionar indivíduos aleatoriamente, proporcionando chances de reprodução aos mais aptos.
- $f$  (cromossomo) = medida numérica de aptidão

Chances de seleção são proporcionais à aptidão







## Método da Roleta

- Encontre a soma da aptidão  $A_T$  de todos os indivíduos da população:

$$A_T = \sum_{i=1}^N f(i)$$

- Gere um número aleatório  $r$ :  $0 \leq r \leq A_T$
- Selecione o **primeiro** indivíduo da população cuja aptidão somada às aptidões dos indivíduos precedentes é  $\geq r$ :

$$\sum_{i=1}^{k \leq N} f(i) \geq r$$

Exemplo:  $r = 30$

<b>Cromossomo</b>	1	2	3	4	5	6	7	8	9	10
<b>Aptidão</b>	8	2	17	7	2	12	11	7	3	7
$\sum_{i=1} f(i)$	8	10	27	34	36	48	59	66	69	76



## Critérios de parada

- Definir um **Número** Máximo de gerações
- Parar quando o sistema encontrar a **solução** (quando esta é conhecida).
- Parar quando ocorrer a perda de diversidade (**repetição** indivíduos) → Convergir !!!



## Convergência Prematura

### ❑ O que é a Convergência Prematura ?

- O sistema não apresenta mais nenhuma melhora e ainda está longe da situação ideal. Não apresenta mais diversidade da população

### ❑ O que pode causar a Convergência Prematura ?

- Vários indivíduos iguais (pouca diversidade)
- Um super-indivíduo que monopoliza o método da roleta
- Uma baixa taxa de mutação e/ou reprodução

### ❑ O que podemos fazer para evitar ?

- Mexer na função de aptidão (fitness) !!!!!
- Existem técnicas que minimizam a criação de super-indivíduos e que aumentam a pressão seletiva sobre os melhores. São elas:
  - Transformação Exponencial
  - Normalização Linear (NL)



## Evitando a Convergência Prematura

### Transformação Exponencial:

- O novo valor da Aptidão  $f'$  de cada indivíduo será dado por:

$$f'(i) = \sqrt[2]{f(i) + 1}$$

- Reduz a influência do indivíduo mais forte

### Normalização Linear:

- Ordene todos os  $N$  indivíduos em ordem decrescente de avaliação ( $i=1$  menos apto)
- Crie aptidões partindo de um valor mínimo e crescendo linearmente até o valor máximo para cada um dos  $N$  indivíduos

$$A_i = \min + \frac{(\max - \min)}{N - 1} \times (i - 1)$$


❑ **Idéia:** Quanto menor a constante de incremento maior a pressão seletiva sobre os melhores. O valor normalmente usado é  $(\max - \min / N - 1)$ .



## Comparativo

### Exemplo Comparativo:

Rank	6	5	4	3	2	1
Aptidão	200	50	25	15	10	2
Transf. Exponencial	14	7	5	4	3	1
NL (incremento 20)	101	81	61	41	21	1



## Algoritmos de AG mais usual

### □ Possui as seguintes características:

- **Cromossomo:** Representação binária em um vetor
- **Reprodução:** Crossover de 1 ponto
- **Nova geração:** Reprodução (seleção) com substituição da população por Elitismo
- **Convergência Prematura:** Normalização Linear
- **Outros detalhes:** usa-se Mutação

**Apresenta bom desempenho em diversas aplicações (é um bom algoritmo de partida).**



## Um exemplo simples

O problema do Caixeiro Viajante:

Encontre um caminho entre as cidades de modo que:

- Cada cidade seja visitada apenas uma vez
- A distância total de viagem seja minimizada

▫ Para um problema com 30 cidades, teremos algo como 30! (fatorial) possibilidades de caminhos

▫  $30! \approx 10^{32}$



## Representação

Iremos considerar um modo simples de representação:

- Lista ordenada de cidades visitadas
- Cada cidade será representada por um número

1) São Paulo	3) SBCampo	5) Diadema	7) Guarulhos
2) Campinas	4) Sto André	6) Osasco	8) SCSul

CityList1 (3 5 7 2 1 6 4 8)

CityList2 (2 5 7 6 8 1 3 4)



## Definindo o Crossover

Iremos usar um Crossover de reprodução de ponto duplo

Pai1	(3	<div style="border: 1px solid black; padding: 2px;">5 7 2 1 6</div>	4 8)
Pai2	(2	<div style="border: 1px solid black; padding: 2px;">5 7 6 8 1</div>	3 4)
<hr style="border: 0.5px solid red;"/>			
Filho	(2	5 7 2 1 6	3 4)




## Definindo a Mutação

Mutação envolve reordenação de lista:


Antes:	(5 8	<div style="border: 1px solid blue; padding: 2px;">7</div>	2 1	<div style="border: 1px solid blue; padding: 2px;">6</div>	3 4)
			↔		
Depois:	(5 8	<div style="border: 1px solid blue; padding: 2px;">6</div>	2 1	<div style="border: 1px solid blue; padding: 2px;">7</div>	3 4)



## Exemplo: 30 Cidades

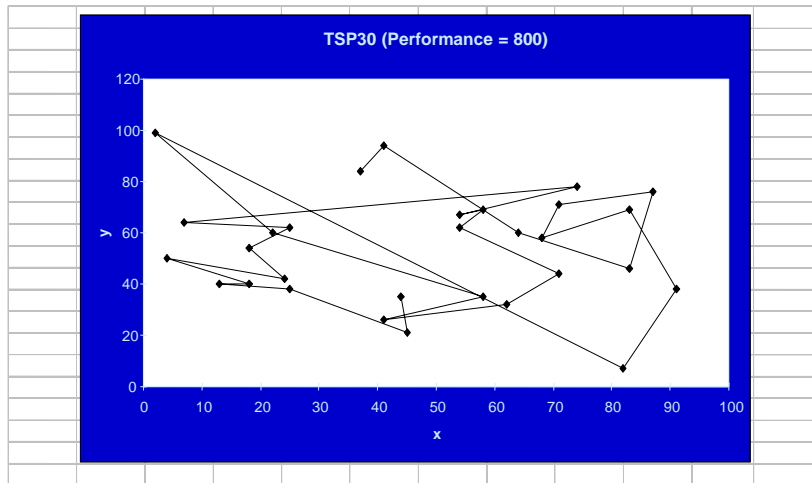


## Solução parcial (Distância = 941)

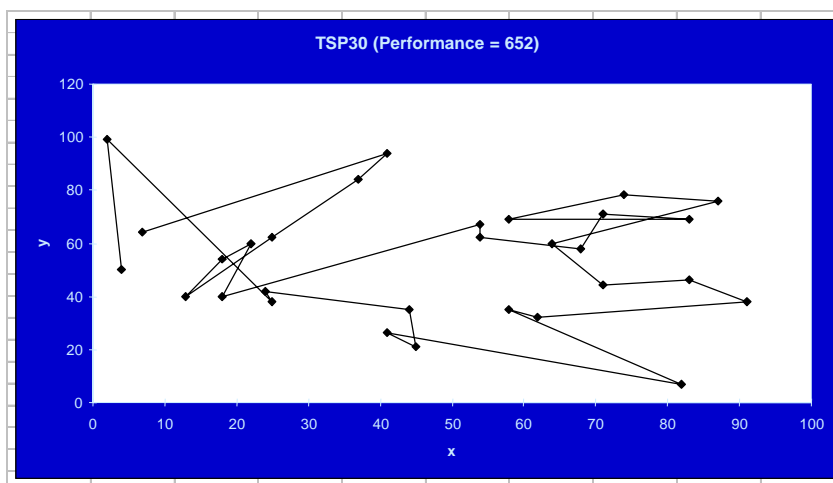




### Solução parcial (Distância = 800)




### Solução parcial (Distância = 652)








## Solução parcial (Distância = 420)



## Gráfico da evolução do AG





## Balanço

### □ Vantagens

- Simples (várias representações, 1 algoritmo) e pouco sensível a pequenas variações
- Vasto campo de aplicações
- Ainda custa caro mas pode ser paralelizado facilmente

### □ Desvantagens

- Como o método é basicamente numérico nem sempre é fácil introduzir conhecimento do domínio
- Se não for paralelizado, pode demorar muito tempo para achar uma solução



## Aplicação prática (CMU robots)




- Fazer o AIBO andar mais rápido
- Aprendeu com Algoritmos Genéticos
- Deixaram alguns AIBOs andando de um lado para outro por dias.
- Eles andavam por x segundos e avaliavam o quanto haviam andado por posicionamento em campo
- Ele se localizava por LANDMARKS nos extremos do campo

<http://www-math.uni-paderborn.de/~junge/images/aibos.jpg>



## Ensinar um quadrúpede andar

- Milton Heinen – Mestrado – 2007 - UNISINOS



- Fitness: Ir mais longe, estável e mais rápido
- Ambiente e sensores Simulados.



## Bibliografia de Algoritmos Genéticos

aprofundamento nos assuntos desta aula, segue a seguinte referência bibliográfica

- **Solange Rezende (Sistemas Inteligentes)**
  - Capítulo 9
- Alguns slides desta aula foram baseados no slides:
- Geber Ramalho: “Algoritmos Evolutivos”, UFPE.
- Wendy Williams. Genetic Algorithms: A tutorial.
- A.E. Eiben e J.E. Smith, Introduction to Evolutionary Computing Genetic Algorithms.
- Luis R. M. Lopes. Fundamentos dos Algoritmos Genéticos.
- Jennifer Pittman. Genetic Algorithm for Variable Selection. Duke University
- Carlos Eduardo Thomaz: Aulas do mestrado em RN. FEI 2010
- Grupo ICA – PUC-Rio